Detección Multimodal de Deepfakes mediante Modelos Visión-Lenguaje: Aplicación y Fine-Tuning de M2F2-Det

Josu Zabala Muxika[1*] and Javier Solana Crespo[1*]

[1*]Escuela Politécnica Superior, Mondragon Unibertsitatea, Bilbao, España.

*Corresponding author(s). E-mail(s): josu.zabala@alumni.mondragon.edu; javier.solana@alumni.mondragon.edu;

Resumen

Se estudia el modelo M2F2-Det (*Multi-Modal Interpretable Forged Face Detector*, CVPR 2025 Oral), que combina CLIP ViT-L/14, DenseNet-121 y LLaVA-7B para detectar y explicar deepfakes. Se implementa el pipeline en Google Colab, obteniendo AUC = 100 % y accuracy = 99,9 % sobre datos GAN. Se diagnostica el fallo del modelo ante imágenes de difusión y se propone un fine-tuning con 9 000 rostros de Stable Diffusion. Tras el reentrenamiento, el modelo detecta correctamente imágenes generadas por difusión con 100 % de confianza.

Keywords: Deepfake Detection, CLIP, Vision-Language Models, Trustworthy AI, Diffusion Models, Fine-Tuning

1 Introducción

La generación de imágenes mediante inteligencia artificial generativa está experimentando una evolución extraordinariamente acelerada: en pocos años hemos pasado de rostros sintéticos apenas convincentes a retratos fotorrealistas prácticamente indistinguibles de una fotografía real, accesibles desde cualquier dispositivo y sin conocimiento técnico previo.

El término *deepfake* designa contenido multimedia generado o manipulado mediante aprendizaje profundo para suplantar identidades o crear contenido engañoso. Desde las redes generativas adversarias (GANs) [4], los deepfakes han evolucionado con los modelos de difusión [5], capaces de producir imágenes fotorrealistas sin precedentes.

La detección automática de deepfakes es un pilar del **Trustworthy AI**, ya que la desinformación visual puede afectar a procesos democráticos y erosionar la confianza pública. La UE clasifica los sistemas de generación de contenido sintético como de alto riesgo [11].

La motivación central de este trabajo surge precisamente de ese **desafío**: millones de personas están generando *deepfakes* y tener una herramienta que permita detectarlos de forma fiable es crucial para combatir la desinformación.

En este trabajo se toma como punto de partida el modelo M2F2-Det publicado por Guo et al. y se realizan diversas modificaciones y adaptaciones sobre él. En primer lugar, se despliega e implementa el pipeline completo en Google Colab, resolviendo múltiples problemas de compatibilidad con las librerías actuales. A continuación, se entrena el módulo detector binario (Stage 1) desde cero sobre un dataset propio, se analiza su rendimiento sobre deepfakes GAN y se diagnostica su fallo ante imágenes generadas por modelos de difusión. Finalmente, se propone y ejecuta un fine-tuning del modelo con datos de Stable Diffusion que resuelve esta limitación, demostrando la capacidad de adaptación de la arquitectura a nuevas técnicas de generación.

2 Estado del Arte

2.1 Detectores basados en redes convolucionales

Los primeros detectores de deepfakes se apoyaban en redes convolucionales profundas entrenadas para identificar artefactos visuales introducidos por los generadores. MesoNet [12] utilizó una arquitectura ligera centrada en características de nivel medio para distinguir rostros GAN de rostros reales. FaceForensics++ [13] estableció el benchmark de referencia del área e impulsó el uso de XceptionNet como backbone estándar. Estos métodos alcanzan resultados sobresalientes dentro de su dominio de entrenamiento, pero generalizan mal ante técnicas de generación no vistas: al estar entrenados sobre artefactos propios de una familia de modelos (p. ej., GAN), fallan ante distribuciones nuevas como los modelos de difusión.

2.2 Detectores multimodales y visión-lenguaje

Para superar la falta de generalización y la ausencia de explicabilidad, la investigación reciente ha explorado integrar modelos visión-lenguaje en la detección de

deepfakes. CLIP [2] ha demostrado ser un descriptor visual potente incluso en dominios forenses, gracias a sus representaciones semánticas de alto nivel. Sin embargo, su entrenamiento contrastivo sobre imágenes naturales hace que considere "reales" las imágenes fotorrealistas, independientemente de si son sintéticas.

Guo et al. [1] proponen **M2F2-Det** (CVPR 2025 Oral), que combina un encoder visual CLIP, una red DenseNet-121 especializada en artefactos de textura y un LLM (LLaVA-7B) para ofrecer simultáneamente detección binaria y explicación textual en lenguaje natural. Este enfoque multimodal e interpretable representa el estado del arte en detección de deepfakes basada en modelos visión-lenguaje y constituye el punto de partida del presente trabajo.

3 Fundamentos Técnicos

Para entender bien el recorrido seguido en este trabajo, conviene conocer las dos principales familias de modelos generativos de imágenes: las GANs, sobre cuyas imágenes se entrenaron los primeros detectores, y los modelos de difusión, que representan el paradigma actual y cuya irrupción motiva el fine-tuning realizado. A continuación se describen también los componentes clave de la arquitectura M2F2-Det.

3.1 Redes Generativas Adversarias (GANs)

Las Redes Generativas Adversarias [4], propuestas por Goodfellow et al. en 2014, fueron durante casi una década el paradigma dominante en la síntesis de imágenes. Su principio de funcionamiento es *adversarial*: un **generador** aprende a crear imágenes artificiales que confundan a un **discriminador**, mientras que este último aprende a distinguir las imágenes reales de las falsas. El entrenamiento simultáneo de ambas redes conduce a un equilibrio dinámico en el que el generador produce imágenes progresivamente más realistas.

Hasta aproximadamente 2022, variantes como StyleGAN y ProGAN representaban el estado del arte en síntesis de rostros y constituían la principal fuente de deepfakes. Sin embargo, el proceso adversarial introduce **artefactos visuales característicos**: inconsistencias espectrales en altas frecuencias, patrones de tipo *checkerboard* y deformaciones sutiles en zonas como ojos, orejas o dientes. Estos artefactos, aunque en muchos casos invisibles al ojo humano, son detectables por redes neuronales especializadas y constituyen la "firma" que modelos como MesoNet o XceptionNet aprenden a identificar.

En la actualidad, los grandes sistemas de generación de imágenes como ChatGPT (DALL-E 3), Google Gemini (NanoBanana) o Grok (Aurora, de xAI) han abandonado las GANs en favor de los **modelos de difusión**. A diferencia de las GANs, que *engañaban* a un discriminador para que algo pareciera real, estas nuevas técnicas construyen la imagen sobre una base matemática mucho más sólida, eliminando el ruido de forma iterativa y controlada. El resultado es que las imágenes generadas por difusión ya no presentan esas deformaciones extrañas ni los artefactos espectrales que caracterizaban los deepfakes de hace apenas unos años. Como consecuencia directa, **los clasificadores entrenados exclusivamente con datos GAN fallan ante**

imágenes de difusión: los patrones que aprendieron a detectar han desaparecido. Esta observación es la que motiva el fine-tuning presentado en la Sección 5.

3.2 Modelos de difusión

Los modelos de difusión [5, 6] generan imágenes mediante eliminación iterativa de ruido, partiendo de ruido gaussiano puro. El proceso de *forward diffusion* degrada una imagen real añadiendo ruido gaussiano en T pasos hasta obtener ruido puro; el modelo aprende a invertir este proceso paso a paso (*reverse diffusion*), guiado por un descriptor textual o visual. **Stable Diffusion** opera en un espacio latente comprimido, lo que reduce el coste computacional; sus variantes (SD 1.5 a 512×512, SD 2.1 a 768×768 y SDXL a 1024×1024) producen texturas suaves y extremadamente naturales. Al no existir el proceso adversarial de las GANs, los artefactos espectrales desaparecen, generando imágenes fotorrealistas sin las deformaciones características que los detectores tradicionales buscan.

3.3 CLIP

CLIP (*Contrastive Language-Image Pre-training*) [2] es un modelo multimodal de OpenAI que aprende representaciones conjuntas de imágenes y texto mediante aprendizaje contrastivo sobre 400 millones de pares imagen-texto. Consta de un Vision Transformer (ViT) [8] y un Transformer textual [9], entrenados para maximizar la similitud coseno entre pares correspondientes mediante la pérdida InfoNCE.

En detección de deepfakes, CLIP aporta representaciones semánticas que capturan la relación entre la apariencia visual y descripciones como "a real face" o "a manipulated face". La variante utilizada es **ViT-L/14@336** (24 capas, embeddings de 1024 dimensiones). Sin embargo, estas representaciones pueden sesgar la predicción hacia "real" cuando la imagen generada es visualmente coherente, como ocurre con los modelos de difusión.

3.4 DenseNet-121

DenseNet-121 [7] conecta cada capa con todas las siguientes mediante conexiones densas, favoreciendo la reutilización de características. En M2F2-Det actúa como *deepfake encoder*, extrayendo características de textura y frecuencia que complementan las representaciones semánticas de CLIP.

4 Arquitectura del M2F2-Det

M2F2-Det [1] opera en tres etapas: Stage 1 realiza la clasificación binaria real/falso, Stage 2 alinea las representaciones del detector con el espacio del modelo de lenguaje, y Stage 3 genera una explicación textual de la decisión. La Figura 1 muestra el pipeline completo.

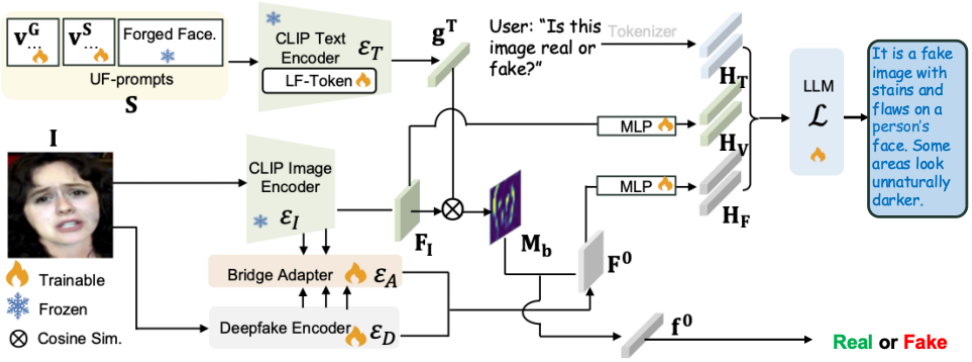

Figura 1 Arquitectura de M2F2-Det [1].

La imagen de entrada $\mathbf{I}$ se procesa en paralelo por el CLIP Image Encoder ($\mathcal{E}_I$), el Deepfake Encoder ($\mathcal{E}_D$) y el Bridge Adapter ($\mathcal{E}_A$). El CLIP Text Encoder ($\mathcal{E}_T$) codifica los UF-prompts de detección. Las representaciones se fusionan mediante similitud coseno ($\mathbf{M}_b$) y proyecciones MLP para producir, por un lado, la clasificación binaria *Real or Fake* (vector $\mathbf{f}^0$) y, por otro, una explicación textual generada por el LLM $\mathcal{L}$ a partir de los tokens $\mathbf{H}_T$, $\mathbf{H}_V$ y $\mathbf{H}_F$. Los módulos marcados como *Trainable* se actualizan durante el entrenamiento; los marcados como *Frozen* permanecen fijos.

En Stage 1, el **CLIP-Vision Encoder** (ViT-L/14@336, congelado) extrae una representación semántica global, mientras que **DenseNet-121** (entrenable) detecta artefactos a nivel de textura mediante average pooling espacial sobre sus mapas de características. El **CLIP-Text Encoder** calcula la similitud coseno entre los parches visuales y prompts de detección como *"a real face"* o *"a forged face"*. Las tres representaciones se concatenan y pasan por una capa lineal que produce la clasificación final. En Stage 2 y 3, los embeddings de Stage 1 se alinean con el espacio de LLaVA-v1.5-7B [3] para que el LLM pueda generar una explicación textual describiendo los indicios visuales que justifican la decisión.

5 Metodología Experimental

Todo el trabajo se realizó en notebooks `.ipynb` desde VS Code mediante la extensión de Google Colab para usar GPUs (T4/A100).

5.1 Pipeline de inferencia

El punto de partida fue portar el código original de Guo et al. [1] a un notebook de Jupyter para poder ejecutarlo de forma interactiva. Esto requirió resolver múltiples incompatibilidades con versiones actuales de librerías: cuantización 4-bit, fallback de flash attention y descarga de pesos ($\sim$16 GB totales). Una vez funcionando, se ejecutó el pipeline completo de inferencia con Stage 1 (detección binaria) y Stage 3 (detección con explicación textual vía LLaVA-7B en 4-bit).

Las primeras pruebas revelaron comportamientos preocupantes. El modelo clasificó como **falsa** una fotografía real de una persona con síndrome de Down, con una confianza elevada. Esto sugiere que el modelo no detecta deepfakes por artefactos técnicos de manipulación, sino que ha aprendido atajos estadísticos: si la cara presenta rasgos que se alejan del patrón facial más frecuente en su dataset de entrenamiento (FaceForensics++, compuesto principalmente por caras normativas), el modelo lo interpreta como señal de falsificación. Por el contrario, imágenes generadas por IA con rasgos genéricos y aspecto fotográfico convencional las clasificaba como **reales con 100 % de confianza**.

5.2 Entrenamiento y fine-tuning

Para corregir este comportamiento se optó por entrenar el módulo Stage 1 con un dataset propio de imágenes reales (FFHQ) frente a imágenes generadas por GAN (StyleGAN). El fine-tuning parte de los pesos pretrained del modelo original y los ajusta con las nuevas imágenes, sin olvidar lo aprendido, lo que permite redirigir la atención del modelo hacia artefactos técnicos de la generación en lugar de rasgos faciales. Se utilizó un split 80/10/10, DenseNet-121 entrenable con CLIP congelado, Adam (lr $= 10^{-4}$), CrossEntropyLoss y mixed precision durante 10 épocas.

Tras el reentrenamiento, el modelo v1 funcionaba correctamente sobre deepfakes GAN y ya no clasificaba erróneamente la imagen de la persona con síndrome de Down. La Figura 2 muestra la predicción correcta del modelo v1 sobre esta imagen.

Figura 2 Predicción del modelo v1 sobre la fotografía real de una persona con síndrome de Down. Tras el fine-tuning con datos GAN, el modelo la clasifica correctamente como REAL.

Sin embargo, al probarlo con imágenes generadas por Grok (modelos de difusión), volvía a fallar: las clasificaba como reales con máxima confianza. El análisis de las señales internas confirmó que tanto CLIP como DenseNet votaban "real" con probabilidades superiores al 97 %, lo que indica que los artefactos de los modelos de difusión

son cualitativamente distintos a los de las GANs y el modelo simplemente no los había visto durante el entrenamiento.

Para resolver esto se preparó un segundo dataset con 9 000 rostros generados por Stable Diffusion 1.5, 2.1 y SDXL[1] y se realizó un segundo fine-tuning (v2) partiendo de los pesos del modelo v1, con lr $= 5 \times 10^{-5}$ y 20 épocas. Al tratarse del mismo tipo de artefacto que producen Grok, DALL-E o Midjourney, el modelo generaliza bien a todos ellos.

Figura 3 Muestras del dataset *stable-diffusion-face-dataset* utilizado para el fine-tuning v2. Rostros generados sintéticamente por modelos de difusión (SD 1.5/2.1/SDXL).

6 Resultados

6.1 Entrenamiento v1: Datos GAN

La Tabla 1 muestra la evolución del entrenamiento v1 (StyleGAN + FFHQ).

Tabla 1 Evolución del entrenamiento v1 (datos GAN).

Época	Train Loss	Train Acc	Val Loss	Val Acc	Val AUC
1	0,2260	89,9 %	0,0464	98,8 %	99,93 %
3	0,0527	97,8 %	0,0223	99,2 %	99,97 %
5	0,0414	98,4 %	0,0183	99,6 %	99,98 %
10	0,0188	99,2 %	0,0120	99,7 %	99,99 %

Sobre el conjunto de test (1 000 imágenes: 500 reales, 500 falsas GAN): Accuracy = 99,9 %, AUC-ROC = 100 %, F1 = 99,9 %, Precision = 100 %, Recall = 99,8 %. Solo 1 falso negativo de 500 imágenes falsas. La Figura 4 muestra la matriz de confusión, la curva ROC y las curvas de entrenamiento.

[1] https://github.com/tobecwb/stable-diffusion-face-dataset

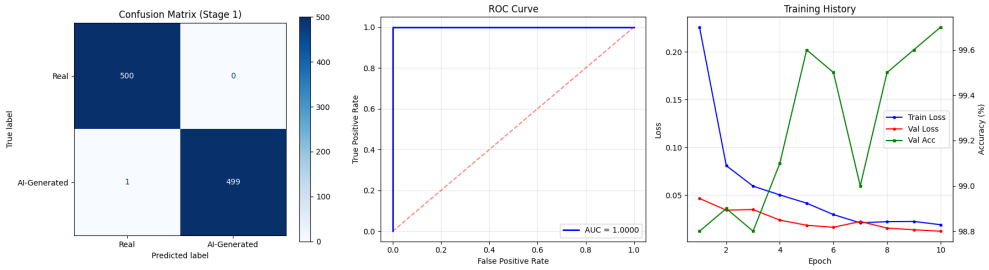

Figura 4 Resultados del entrenamiento v1 (datos GAN). Izquierda: matriz de confusión (500/500 reales correctas, 499/500 falsas correctas). Centro: curva ROC (AUC = 1,0000). Derecha: evolución de loss y accuracy.

Los mapas Grad-CAM sobre `denseblock4` confirmaron que el modelo concentra su atención en la zona periocular, bordes del rostro y textura de la piel, regiones donde las GANs producen artefactos característicos.

6.2 Predicciones individuales

La Tabla 2 muestra las predicciones sobre imágenes heterogéneas del modelo v1.

Tabla 2 Predicciones del modelo v1 sobre imágenes de test.

Imagen	Tipo real	Predicción	Confianza
Imagen IA nº1 (StyleGAN)	AI-Gen	AI-Gen	93,1 %
Imagen IA nº2 (StyleGAN)	AI-Gen	AI-Gen	100,0 %
Foto real nº1	Real	Real	100,0 %
Foto real nº2	Real	Real	53,3 %
Imagen difusión (Grok)	AI-Gen	**Real**	**100,0 %**

La Figura 5 muestra las predicciones del modelo sobre cada imagen.

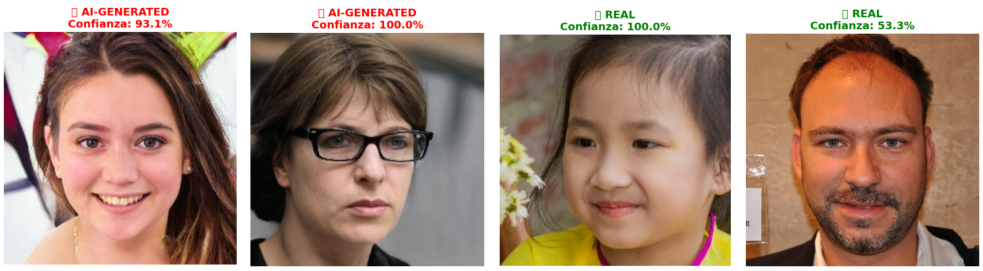

Figura 5 Predicciones del modelo v1 sobre imágenes de test.

El modelo detecta correctamente las imágenes GAN pero falla completamente ante imágenes de difusión, clasificándolas como reales con máxima confianza.

6.3 Fine-tuning v2: Datos de difusión

Tras el reentrenamiento con datos de Stable Diffusion, el modelo v2 converge rápidamente, alcanzando AUC = 100 % y Accuracy = 100 % desde la época 2 (Tabla 3).

Tabla 3 Evolución del entrenamiento v2 (datos de difusión).

Época	Train Loss	Train Acc	Val Loss	Val Acc	Val AUC
1	0,1162	96,4 %	0,0036	99,9 %	100,0 %
2	0,0091	99,7 %	0,0009	100,0 %	100,0 %
5	0,0019	99,9 %	0,0004	100,0 %	100,0 %
10	0,0005	100,0 %	0,0003	100,0 %	100,0 %
20	0,0001	100,0 %	0,0001	100,0 %	100,0 %

Tras cargar los pesos del mejor checkpoint, se evaluó el modelo v2 sobre imágenes de prueba generados con IA. La imagen `fake_carnet.jpg` que anteriormente fue clasificada como real por el modelo v1, ahora es correctamente identificada como AI-GENERATED con 100,0 % de confianza. La Figura 6 muestra esta predicción.

Figura 6 Predicción del modelo v2 (fine-tuned con datos de difusión) sobre una imagen generada por IA. El modelo clasifica correctamente la imagen como AI-GENERATED con 100 % de confianza, resolviendo el fallo del modelo v1.

7 Discusión

7.1 Gap de dominio GAN-difusión

Los resultados confirman que la arquitectura M2F2-Det es altamente efectiva para detectar deepfakes GAN (AUC = 100 %), pero el detector aprende artefactos específicos de la técnica de generación, no características universales de artificialidad.

Las GANs producen patrones espectrales característicos (artefactos de checkerboard, inconsistencias en altas frecuencias) que DenseNet-121 detecta eficazmente. Los modelos de difusión generan texturas más naturales mediante refinamiento iterativo, con artefactos cualitativamente diferentes.

El análisis de señales internas confirmó que ambas ramas fallan: CLIP porque su entrenamiento contrastivo produce representaciones semánticas (no forenses), y DenseNet porque sus filtros se especializaron en artefactos GAN. Los parámetros α aprendidos ($\alpha_{\text{vis}} = 0{,}6244$, $\alpha_{\text{txt}} = 4{,}4632$) indican que el modelo otorga mucho más peso a la rama textual, amplificando el sesgo semántico.

7.2 Eficacia del fine-tuning y limitaciones

El fine-tuning v2 resuelve completamente el fallo de detección de imágenes de difusión, con convergencia muy rápida (AUC = 100 % en 2 épocas). Esto indica que los artefactos de difusión, aunque diferentes a los de GAN, son igualmente discriminables una vez incluidos en los datos de entrenamiento.

Sin embargo, existen limitaciones conocidas: (1) el modelo v2 podría especializarse en Stable Diffusion y fallar ante otros generadores (DALL-E, Midjourney, Flux); (2) existe riesgo de *catastrophic forgetting* sobre datos GAN; (3) el dataset de 4 500 imágenes por clase es relativamente pequeño. Además, las explicaciones del LLM (Stage 3) pueden ser convincentes pero incorrectas, planteando riesgos de *falsa confianza* que subrayan la necesidad de nunca confiar exclusivamente en la explicación textual.

8 Conclusiones

Se ha implementado y evaluado M2F2-Det para la detección multimodal de deepfakes, desplegando el pipeline completo en Google Colab. El modelo entrenado con datos GAN alcanza un rendimiento excepcional (AUC = 100 %, Accuracy = 99,9 %), pero falla ante imágenes de difusión. Mediante análisis de señales internas se diagnosticó que tanto CLIP como DenseNet fallan ante estos artefactos. El fine-tuning con 9 000 imágenes de Stable Diffusion (1.5/2.1/SDXL) resuelve completamente esta limitación, alcanzando AUC = 100 % y detectando imágenes de difusión con 100 % de confianza. Estos resultados demuestran la eficacia de la fusión CLIP + DenseNet + Bridge Adapter y la importancia de incluir datos representativos de cada técnica de generación en el entrenamiento.

References

[1] Guo, X., Zhang, Y., Liu, J., Lyu, S.: Rethinking vision-language model in face forensics: Multi-modal interpretable forged face detector. In: CVPR, pp. 1–12 (2025). https://arxiv.org/abs/2503.20188

[2] Radford, A., Kim, J.W., Hallacy, C., et al.: Learning transferable visual models from natural language supervision. In: ICML, pp. 8748–8763. PMLR (2021). https://arxiv.org/abs/2103.00020

[3] Liu, H., Li, C., Wu, Q., Lee, Y.J.: Visual instruction tuning. In: NeurIPS, vol. 36 (2023) https://arxiv.org/pdf/2304.08485

[4] Goodfellow, I., Pouget-Abadie, J., Mirza, M., et al.: Generative adversarial nets. In: NeurIPS, vol. 27 (2014) https://arxiv.org/pdf/1406.2661

[5] Rombach, R., Blattmann, A., Lorenz, D., Esser, P., Ommer, B.: High-resolution image synthesis with latent diffusion models. In: CVPR, pp. 10684–10695 (2022)

[6] Ho, J., Jain, A., Abbeel, P.: Denoising diffusion probabilistic models. In: NeurIPS, vol. 33, pp. 6840–6851 (2020)

[7] Huang, G., Liu, Z., Van Der Maaten, L., Weinberger, K.Q.: Densely connected convolutional networks. In: CVPR, pp. 4700–4708 (2017)

[8] Dosovitskiy, A., Beyer, L., Kolesnikov, A., et al.: An image is worth 16x16 words: Transformers for image recognition at scale. In: ICLR (2021)

[9] Vaswani, A., Shazeer, N., Parmar, N., et al.: Attention is all you need. In: NeurIPS, vol. 30 (2017)

[10] Selvaraju, R.R., Cogswell, M., Das, A., et al.: Grad-CAM: Visual explanations from deep networks via gradient-based localization. In: ICCV, pp. 618–626 (2017)

[11] European Parliament and Council of the European Union: Regulation (EU) 2024/1689 — Artificial Intelligence Act. Official Journal of the EU, L series (2024)

[12] Afchar, D., Nozick, V., Yamagishi, J., Echizen, I.: MesoNet: A compact facial video forgery detection network. In: IEEE International Workshop on Information Forensics and Security (WIFS), pp. 1–7 (2018)

[13] Rössler, A., Cozzolino, D., Verdoliva, L., Riess, C., Thies, J., Nießner, M.: FaceForensics++: Learning to detect manipulated facial images. In: ICCV, pp. 1–11 (2019)