Detección Multimodal de Deepfakes mediante Modelos Visión-Lenguaje: Aplicación y Fine-Tuning de M2F2-Det

Josu Zabala Muxika[1*] and Javier Solana Crespo[1*]

[1*]Escuela Politécnica Superior, Mondragon Unibertsitatea, Bilbao, España.

*Corresponding author(s). E-mail(s):
josu.zabala@alumni.mondragon.edu;
javier.solana@alumni.mondragon.edu;

Resumen

Se estudia el modelo M2F2-Det (*Multi-Modal Interpretable Forged Face Detector*, CVPR 2025 Oral), que combina CLIP ViT-L/14, DenseNet-121 y LLaVA-7B para detectar y explicar deepfakes. Se implementa el pipeline en Google Colab, obteniendo AUC = 100 % y accuracy = 99,9 % sobre datos GAN. Se diagnostica el fallo del modelo ante imágenes de difusión y se propone un fine-tuning con 9 000 rostros de Stable Diffusion. Tras el reentrenamiento, el modelo detecta correctamente imágenes generadas por difusión con 100 % de confianza.

Keywords: Deepfake Detection, CLIP, Vision-Language Models, Trustworthy AI, Diffusion Models, Fine-Tuning

1 Introducción

La generación de imágenes mediante inteligencia artificial generativa está experimentando una evolución extraordinariamente acelerada: en pocos años hemos pasado de rostros sintéticos apenas convincentes a retratos fotorrealistas prácticamente indistinguibles de una fotografía real, accesibles desde cualquier dispositivo y sin conocimiento técnico previo.

El término *deepfake* designa contenido multimedia generado o manipulado mediante aprendizaje profundo para suplantar identidades o crear contenido engañoso. Desde las redes generativas adversarias (GANs) [4], los deepfakes han evolucionado con los modelos de difusión [5], capaces de producir imágenes fotorrealistas sin precedentes.

La detección automática de deepfakes es un pilar del **Trustworthy AI**, ya que la desinformación visual puede afectar a procesos democráticos y erosionar la confianza pública. La UE clasifica los sistemas de generación de contenido sintético como de alto riesgo [11].

La motivación central de este trabajo surge precisamente de ese **desafío**: millones de personas están generando *deepfakes* y tener una herramienta que permita detectarlos de forma fiable es crucial para combatir la desinformación.

En este trabajo se toma como punto de partida el modelo M2F2-Det publicado por Guo et al. y se realizan diversas modificaciones y adaptaciones sobre él. En primer lugar, se despliega e implementa el pipeline completo en Google Colab, resolviendo múltiples problemas de compatibilidad con las librerías actuales. A continuación, se entrena el módulo detector binario (Stage 1) desde cero sobre un dataset propio, se analiza su rendimiento sobre deepfakes GAN y se diagnostica su fallo ante imágenes generadas por modelos de difusión. Finalmente, se propone y ejecuta un fine-tuning del modelo con datos de Stable Diffusion que resuelve esta limitación, demostrando la capacidad de adaptación de la arquitectura a nuevas técnicas de generación.

2 Estado del Arte

2.1 Detectores basados en redes convolucionales

Los primeros detectores de deepfakes se apoyaban en redes convolucionales profundas entrenadas para identificar artefactos visuales introducidos por los generadores. MesoNet [12] utilizó una arquitectura ligera centrada en características de nivel medio para distinguir rostros GAN de rostros reales. FaceForensics++ [13] estableció el benchmark de referencia del área e impulsó el uso de XceptionNet como backbone estándar. Estos métodos alcanzan resultados sobresalientes dentro de su dominio de entrenamiento, pero generalizan mal ante técnicas de generación no vistas: al estar entrenados sobre artefactos propios de una familia de modelos (p. ej., GAN), fallan ante distribuciones nuevas como los modelos de difusión.

2.2 Detectores multimodales y visión-lenguaje

Para superar la falta de generalización y la ausencia de explicabilidad, la investigación reciente ha explorado integrar modelos visión-lenguaje en la detección de

deepfakes. CLIP [2] ha demostrado ser un descriptor visual potente incluso en dominios forenses, gracias a sus representaciones semánticas de alto nivel. Sin embargo, su entrenamiento contrastivo sobre imágenes naturales hace que considere "reales" las imágenes fotorrealistas, independientemente de si son sintéticas.

Guo et al. [1] proponen **M2F2-Det** (CVPR 2025 Oral), que combina un encoder visual CLIP, una red DenseNet-121 especializada en artefactos de textura y un LLM (LLaVA-7B) para ofrecer simultáneamente detección binaria y explicación textual en lenguaje natural. Este enfoque multimodal e interpretable representa el estado del arte en detección de deepfakes basada en modelos visión-lenguaje y constituye el punto de partida del presente trabajo.

3 Fundamentos Técnicos

Para entender bien el recorrido seguido en este trabajo, conviene conocer las dos principales familias de modelos generativos de imágenes: las GANs, sobre cuyas imágenes se entrenaron los primeros detectores, y los modelos de difusión, que representan el paradigma actual y cuya irrupción motiva el fine-tuning realizado. A continuación se describen también los componentes clave de la arquitectura M2F2-Det.

3.1 Redes Generativas Adversarias (GANs)

Las Redes Generativas Adversarias [4], propuestas por Goodfellow et al. en 2014, fueron durante casi una década el paradigma dominante en la síntesis de imágenes. Su principio de funcionamiento es *adversarial*: un **generador** aprende a crear imágenes artificiales que confundan a un **discriminador**, mientras que este último aprende a distinguir las imágenes reales de las falsas. El entrenamiento simultáneo de ambas redes conduce a un equilibrio dinámico en el que el generador produce imágenes progresivamente más realistas.

Hasta aproximadamente 2022, variantes como StyleGAN y ProGAN representaban el estado del arte en síntesis de rostros y constituían la principal fuente de deepfakes. Sin embargo, el proceso adversarial introduce **artefactos visuales característicos**: inconsistencias espectrales en altas frecuencias, patrones de tipo *checkerboard* y deformaciones sutiles en zonas como ojos, orejas o dientes. Estos artefactos, aunque en muchos casos invisibles al ojo humano, son detectables por redes neuronales especializadas y constituyen la "firma" que modelos como MesoNet o XceptionNet aprenden a identificar.

En la actualidad, los grandes sistemas de generación de imágenes como ChatGPT (DALL-E 3), Google Gemini (NanoBanana) o Grok (Aurora, de xAI) han abandonado las GANs en favor de los **modelos de difusión**. A diferencia de las GANs, que *engañaban* a un discriminador para que algo pareciera real, estas nuevas técnicas construyen la imagen sobre una base matemática mucho más sólida, eliminando el ruido de forma iterativa y controlada. El resultado es que las imágenes generadas por difusión ya no presentan esas deformaciones extrañas ni los artefactos espectrales que caracterizaban los deepfakes de hace apenas unos años. Como consecuencia directa, **los clasificadores entrenados exclusivamente con datos GAN fallan ante**

imágenes de difusión: los patrones que aprendieron a detectar han desaparecido. Esta observación es la que motiva el fine-tuning presentado en la Sección 5.

3.2 Modelos de difusión

Los modelos de difusión [5, 6] generan imágenes mediante eliminación iterativa de ruido, partiendo de ruido gaussiano puro. El proceso de *forward diffusion* degrada una imagen real añadiendo ruido gaussiano en T pasos hasta obtener ruido puro; el modelo aprende a invertir este proceso paso a paso (*reverse diffusion*), guiado por un descriptor textual o visual. **Stable Diffusion** opera en un espacio latente comprimido, lo que reduce el coste computacional; sus variantes (SD 1.5 a 512×512, SD 2.1 a 768×768 y SDXL a 1024×1024) producen texturas suaves y extremadamente naturales. Al no existir el proceso adversarial de las GANs, los artefactos espectrales desaparecen, generando imágenes fotorrealistas sin las deformaciones características que los detectores tradicionales buscan.

3.3 CLIP

CLIP (*Contrastive Language-Image Pre-training*) [2] es un modelo multimodal de OpenAI que aprende representaciones conjuntas de imágenes y texto mediante aprendizaje contrastivo sobre 400 millones de pares imagen-texto. Consta de un Vision Transformer (ViT) [8] y un Transformer textual [9], entrenados para maximizar la similitud coseno entre pares correspondientes mediante la pérdida InfoNCE.

En detección de deepfakes, CLIP aporta representaciones semánticas que capturan la relación entre la apariencia visual y descripciones como "a real face" o "a manipulated face". La variante utilizada es **ViT-L/14@336** (24 capas, embeddings de 1024 dimensiones). Sin embargo, estas representaciones pueden sesgar la predicción hacia "real" cuando la imagen generada es visualmente coherente, como ocurre con los modelos de difusión.

3.4 DenseNet-121

DenseNet-121 [7] conecta cada capa con todas las siguientes mediante conexiones densas, favoreciendo la reutilización de características. En M2F2-Det actúa como *deepfake encoder*, extrayendo características de textura y frecuencia que complementan las representaciones semánticas de CLIP.

4 Arquitectura del M2F2-Det

M2F2-Det [1] opera en tres etapas:

4.1 Stage 1: Detector binario

Combina tres ramas: (1) **CLIP-Vision**: ViT-L/14@336 congelado produce un token CLS ($\mathbf{v}_{\text{cls}} \in \mathbb{R}^{1024}$) escalado por α_{vis}; (2) **CLIP-Text**: embeddings textuales de prompts de detección, que generan puntuaciones de similitud escaladas por α_{txt};

(3) **DenseNet-121**: red entrenable que extrae características de textura, fusionadas con CLIP mediante un **Bridge Adapter**. Las tres salidas se concatenan:

$$\mathbf{f} = [\alpha_{\text{vis}} \cdot \mathbf{v}_{\text{cls}} \parallel \alpha_{\text{txt}} \cdot \mathbf{c}_{\text{bridge}} \parallel \text{proj}(\text{AvgPool}(\mathbf{d}))] \tag{1}$$

produciendo $\mathbf{f} \in \mathbb{R}^{2176}$ que pasa por $\text{Linear}(2176, 2)$ para clasificación binaria.

4.2 Stage 2 y 3: Alineación y explicación

Stage 2 alinea los embeddings del detector con el espacio de LLaVA-v1.5-7B [3] mediante un projector multimodal. Stage 3 utiliza el LLM completo para generar explicaciones textuales sobre la autenticidad de la imagen, describiendo indicios visuales como textura de piel, simetría y bordes.

En nuestros experimentos, Stage 1 clasificó una imagen manipulada como **FAKE** (78,8 % confianza), mientras que Stage 3 la clasificó erróneamente como real con una explicación convincente pero incorrecta. Esta discrepancia ilustra el sesgo semántico de los LLMs.

5 Metodología Experimental

Todo el trabajo se realizó en notebooks de Google Colab (GPUs T4/A100) conectados desde VS Code.

5.1 Pipeline de inferencia

El primer notebook (19 celdas) implementa el pipeline completo: setup del entorno con parches de compatibilidad (cuantización 4-bit, fallback de flash attention), descarga de pesos (∼16 GB totales), y ejecución de Stage 1 (detección binaria) y Stage 3 (detección + explicación con LLaVA-7B en 4-bit).

5.2 Entrenamiento y fine-tuning

El segundo notebook (32 celdas) implementa:

Entrenamiento v1 (datos GAN): Se utiliza el dataset de FFHQ (reales) + StyleGAN (falsos), equilibrado y dividido en train (80 %), validación (10 %) y test (10 %). Se entrena M2F2Det con DenseNet-121 (`hidden_size=1024`), CLIP congelado, Adam (lr = 10^{-4}), CrossEntropyLoss, batch 32, mixed precision, durante 10 épocas.

Evaluación: Métricas de clasificación, matriz de confusión, curva ROC, mapas Grad-CAM [10] sobre `denseblock4` y predicciones individuales sobre imágenes propias.

Diagnóstico: Al evaluar imágenes generadas por difusión (Grok/Aurora de xAI), el modelo las clasifica como **reales al 100 %**. El análisis de señales internas reveló que tanto CLIP (P(Real) = 99,9 %) como DenseNet (P(Real) = 97,8 %) fallan, confirmando que los artefactos de difusión son cualitativamente diferentes.

Fine-tuning v2 (datos de difusión): Se prepara el dataset `tobecwb/stable-diffusion-face-dataset`[1] con 9 000 rostros (3 000 de SD 1.5, 3 000 de SD 2.1, 3 000 de SDXL, bajo licencia CC-BY-4.0) más 4 500 imágenes reales de FFHQ. División: 3 600/450/450 por clase (train/val/test). Se reentrena durante 20 épocas con lr $= 5 \times 10^{-5}$ y batch efectivo de 64.

6 Resultados

6.1 Entrenamiento v1: Datos GAN

La Tabla 1 muestra la evolución del entrenamiento v1 (StyleGAN + FFHQ).

Tabla 1 Evolución del entrenamiento v1 (datos GAN).

Época	Train Loss	Train Acc	Val Loss	Val Acc	Val AUC
1	0,2260	89,9 %	0,0464	98,8 %	99,93 %
3	0,0527	97,8 %	0,0223	99,2 %	99,97 %
5	0,0414	98,4 %	0,0183	99,6 %	99,98 %
10	0,0188	99,2 %	0,0120	99,7 %	99,99 %

Sobre el conjunto de test (1 000 imágenes: 500 reales, 500 falsas GAN): Accuracy = 99,9 %, AUC-ROC = 100 %, F1 = 99,9 %, Precision = 100 %, Recall = 99,8 %. Solo 1 falso negativo de 500 imágenes falsas. La Figura 1 muestra la matriz de confusión, la curva ROC y las curvas de entrenamiento.

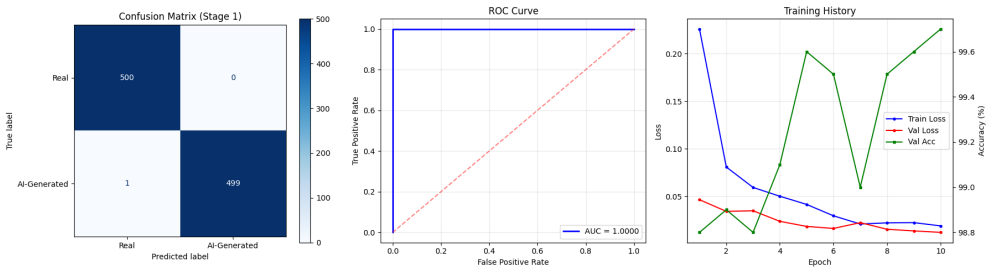

Figura 1 Resultados del entrenamiento v1 (datos GAN). Izquierda: matriz de confusión (500/500 reales correctas, 499/500 falsas correctas). Centro: curva ROC (AUC = 1,0000). Derecha: evolución de loss y accuracy.

Los mapas Grad-CAM sobre `denseblock4` confirmaron que el modelo concentra su atención en la zona periocular, bordes del rostro y textura de la piel, regiones donde las GANs producen artefactos característicos.

[1] https://github.com/tobecwb/stable-diffusion-face-dataset

6.2 Predicciones individuales

La Tabla 2 muestra las predicciones sobre imágenes heterogéneas del modelo v1.

Tabla 2 Predicciones del modelo v1 sobre imágenes de test.

Imagen	Tipo real	Predicción	Confianza
Imagen IA nº1 (StyleGAN)	AI-Gen	AI-Gen	93,1 %
Imagen IA nº2 (StyleGAN)	AI-Gen	AI-Gen	100,0 %
Foto real nº1	Real	Real	100,0 %
Foto real nº2	Real	Real	53,3 %
Imagen difusión (Grok)	AI-Gen	**Real**	**100,0 %**

El modelo detecta correctamente las imágenes GAN pero falla completamente ante imágenes de difusión, clasificándolas como reales con máxima confianza.

6.3 Fine-tuning v2: Datos de difusión

Tras el reentrenamiento con datos de Stable Diffusion, el modelo v2 converge rápidamente, alcanzando AUC = 100 % y Accuracy = 100 % desde la época 2 (Tabla 3).

Tabla 3 Evolución del entrenamiento v2 (datos de difusión).

Época	Train Loss	Train Acc	Val Loss	Val Acc	Val AUC
1	0,1162	96,4 %	0,0036	99,9 %	100,0 %
2	0,0091	99,7 %	0,0009	100,0 %	100,0 %
5	0,0019	99,9 %	0,0004	100,0 %	100,0 %
10	0,0005	100,0 %	0,0003	100,0 %	100,0 %
20	0,0001	100,0 %	0,0001	100,0 %	100,0 %

Tras cargar los pesos del mejor checkpoint (época 2), se evaluó el modelo v2 sobre la imagen de prueba `fake_carnet.jpg` (generada por IA). El resultado fue: **AI-GENERATED con 100,0 % de confianza**, resolviendo completamente el fallo de detección del modelo v1. La Figura 2 muestra esta predicción.

7 Discusión

7.1 Gap de dominio GAN-difusión

Los resultados confirman que la arquitectura M2F2-Det es altamente efectiva para detectar deepfakes GAN (AUC = 100 %), pero el detector aprende artefactos específicos de la técnica de generación, no características universales de artificialidad. Las GANs producen patrones espectrales característicos (artefactos de checkerboard,

Figura 2 Predicción del modelo v2 (fine-tuned con datos de difusión) sobre una imagen generada por IA. El modelo clasifica correctamente la imagen como AI-GENERATED con 100 % de confianza, resolviendo el fallo del modelo v1.

inconsistencias en altas frecuencias) que DenseNet-121 detecta eficazmente. Los modelos de difusión generan texturas más naturales mediante refinamiento iterativo, con artefactos cualitativamente diferentes.

El análisis de señales internas confirmó que ambas ramas fallan: CLIP porque su entrenamiento contrastivo produce representaciones semánticas (no forenses), y DenseNet porque sus filtros se especializaron en artefactos GAN. Los parámetros α aprendidos ($\alpha_{\text{vis}} = 0{,}6244$, $\alpha_{\text{txt}} = 4{,}4632$) indican que el modelo otorga mucho más peso a la rama textual, amplificando el sesgo semántico.

7.2 Eficacia del fine-tuning y limitaciones

El fine-tuning v2 resuelve completamente el fallo de detección de imágenes de difusión, con convergencia muy rápida (AUC = 100 % en 2 épocas). Esto indica que los artefactos de difusión, aunque diferentes a los de GAN, son igualmente discriminables una vez incluidos en los datos de entrenamiento.

Sin embargo, existen limitaciones conocidas: (1) el modelo v2 podría especializarse en Stable Diffusion y fallar ante otros generadores (DALL-E, Midjourney, Flux); (2) existe riesgo de *catastrophic forgetting* sobre datos GAN; (3) el dataset de 4 500 imágenes por clase es relativamente pequeño. Además, las explicaciones del LLM (Stage 3) pueden ser convincentes pero incorrectas, planteando riesgos de *falsa confianza* que subrayan la necesidad de nunca confiar exclusivamente en la explicación textual.

8 Conclusiones

Se ha implementado y evaluado M2F2-Det para la detección multimodal de deepfakes, desplegando el pipeline completo en Google Colab. El modelo entrenado con datos GAN alcanza un rendimiento excepcional (AUC = 100 %, Accuracy = 99,9 %), pero falla ante imágenes de difusión. Mediante análisis de señales internas se diagnosticó que tanto CLIP como DenseNet fallan ante estos artefactos. El fine-tuning con 9 000

imágenes de Stable Diffusion (1.5/2.1/SDXL) resuelve completamente esta limitación, alcanzando AUC = 100 % y detectando imágenes de difusión con 100 % de confianza. Estos resultados demuestran la eficacia de la fusión CLIP + DenseNet + Bridge Adapter y la importancia de incluir datos representativos de cada técnica de generación en el entrenamiento.

References

[1] Guo, X., Zhang, Y., Liu, J., Lyu, S.: Rethinking vision-language model in face forensics: Multi-modal interpretable forged face detector. In: CVPR, pp. 1–12 (2025). https://arxiv.org/abs/2503.20188

[2] Radford, A., Kim, J.W., Hallacy, C., et al.: Learning transferable visual models from natural language supervision. In: ICML, pp. 8748–8763. PMLR (2021). https://arxiv.org/abs/2103.00020

[3] Liu, H., Li, C., Wu, Q., Lee, Y.J.: Visual instruction tuning. In: NeurIPS, vol. 36 (2023) https://arxiv.org/pdf/2304.08485

[4] Goodfellow, I., Pouget-Abadie, J., Mirza, M., et al.: Generative adversarial nets. In: NeurIPS, vol. 27 (2014) https://arxiv.org/pdf/1406.2661

[5] Rombach, R., Blattmann, A., Lorenz, D., Esser, P., Ommer, B.: High-resolution image synthesis with latent diffusion models. In: CVPR, pp. 10684–10695 (2022)

[6] Ho, J., Jain, A., Abbeel, P.: Denoising diffusion probabilistic models. In: NeurIPS, vol. 33, pp. 6840–6851 (2020)

[7] Huang, G., Liu, Z., Van Der Maaten, L., Weinberger, K.Q.: Densely connected convolutional networks. In: CVPR, pp. 4700–4708 (2017)

[8] Dosovitskiy, A., Beyer, L., Kolesnikov, A., et al.: An image is worth 16x16 words: Transformers for image recognition at scale. In: ICLR (2021)

[9] Vaswani, A., Shazeer, N., Parmar, N., et al.: Attention is all you need. In: NeurIPS, vol. 30 (2017)

[10] Selvaraju, R.R., Cogswell, M., Das, A., et al.: Grad-CAM: Visual explanations from deep networks via gradient-based localization. In: ICCV, pp. 618–626 (2017)

[11] European Parliament and Council of the European Union: Regulation (EU) 2024/1689 — Artificial Intelligence Act. Official Journal of the EU, L series (2024)

[12] Afchar, D., Nozick, V., Yamagishi, J., Echizen, I.: MesoNet: A compact facial video forgery detection network. In: IEEE International Workshop on Information Forensics and Security (WIFS), pp. 1–7 (2018)

[13] Rössler, A., Cozzolino, D., Verdoliva, L., Riess, C., Thies, J., Nießner, M.: FaceForensics++: Learning to detect manipulated facial images. In: ICCV, pp. 1–11 (2019)